

Recalage et fusion de modèles numérisés tridimensionnels de grande taille

MEMO-F-403 - Préparation au mémoire

Tim Lenertz

15 août 2014

Table des matières

1	Introduction	3
2	Etat de l'art	4
2.1	Documentation 3D	4
2.1.1	Scanner tridimensionnels	5
2.2	Théorie préliminaire	5
2.2.1	RANSAC	5
2.2.2	Méthode de Newton	5
2.3	Recalage	6
2.3.1	Iterative Closest Point	7
2.4	4-Points Congruent Sets	12
2.5	Normal Distributions Transform	14
2.6	Extended Gaussian Images	15
2.7	Extended Gaussian Images	15
2.8	Identification et correspondance de droites	15
2.9	Identification et correspondance de plans	15
2.10	Détecteurs de zones d'intérêt	15
2.11	Recalage via des photos	15
2.12	Photogrammétrie	15
3	Projet prévu pour le mémoire	16

1 Introduction

Pour des projets de documentation 3D, des objets ou environnements sont souvent numérisés sous forme de *nuages de points*. Un nuage de points consiste uniquement en un ensemble de points situés sur les surfaces des objets, définis par des coordonnées dans un repère orthonormal donné, et attribués par des valeurs scalaires ou vectorielles comme par exemple une couleur RGB.

Ces jeux de données sont usuellement capturés par des scanners 3D à télémètre laser, ou par photogrammétrie. Ces données brutes ne représentent qu'une partie de l'objet, et sont limitées par le champ de vision de la caméra, les surfaces cachées (sur le côté opposé au scanner de l'objet), les limites de résolution pour des parties éloignées ou qui ont une texture complexe. Afin d'en synthétiser un nuage de points représentant le modèle complet, plusieurs traitements doivent être effectués, notamment le recalage : Pour toutes les nuages de points partielles, une transformation affine est appliquée aux points afin de les mettre dans un repère commun.

Plusieurs techniques (semi)-automatisées ont été développées qui permettent de trouver une approximation des positions et orientations relatifs des scans. Ils peuvent faire intervenir des photos, ou des marqueurs visuels ajoutés sur la scène. La matrice de transformation précise est ensuite déterminée algorithmiquement, afin de bien aligner les surfaces dans les différents ensembles de points. Typiquement, une forme de l'algorithme ICP¹ est utilisé, un algorithme qui ajuste la transformation en itérativement minimisant la distance entre les deux ensembles de points.

Ce mémoire se concentre sur le recalage de numérisations à distance d'un objet à grande dimensions, avec des numérisations à courtes distances de détails de l'objet. Donc les ensembles de points à recaler pourront avoir des densités de points très différentes, et auront un nombre de points très élevé. Le but est d'établir un workflow et de développer des algorithmes qui permettent d'effectuer ce type de recalage. Le travail est basé sur un projet de documentation 3D actuel du LISA.

1. Iterative Closest Point

2 Etat de l'art

2.1 Documentation 3D

Des nuages de points créés via des processus de numérisation 3D sont utilisés dans plusieurs domaines pour représenter des objets réels. Les modèles 3D peuvent passer de représentations détaillées d'objets petits à des bâtiments ou même des sites entiers. Des exemples d'usage sont par exemple la documentation détaillée de sites archéologiques [4] [9] [19] et d'environnements urbains [12], des acquisitions aériennes de terrains, la vision algorithmique en robotique [2], la capture de formes 3D pour création de prothèses en médecine dentaire et orthopédique, la rétroingénierie, la création de modèles en animation 3D.

Pour collectionner les données brutes de l'objet pour lequel on veut générer un modèle 3D, deux techniques sont généralement utilisées : La *photogrammétrie* consiste à prendre des photos (possiblement stéréoscopiques) de l'objet, à partir desquelles on peut extraire algorithmiquement de l'information sur la profondeur des pixels. D'autre part, on utilise des *scanners tridimensionnels*, des appareils qui effectuent un balayage par laser de l'objet et produisent directement un nuage de points. Souvent les deux techniques sont combinées. Cela permet par exemple de compléter un scan laser très détaillé avec de l'information sur les couleurs des points.

Pour passer des données brutes au modèle final envisagé, un nombre important d'étapes de planification et de post-traitement des données doivent être effectués. Par exemple, un projet de documentation archéologique pour lequel des scans 3D et des données photogrammétriques sont utilisés peut passer par les étapes suivantes : [23]

- Planification et acquisition des données brutes. Les positions à partir desquelles les scans 3D sont pris doivent être planifiés minutieusement en fonction du terrain, de la forme de l'objet et des spécifications du scanner, afin d'assurer une couverture complète de l'objet, avec la résolution et fidélité ciblée. De même pour les position où des photos sont prises.
- Filtrage des nuages de points bruts. Le but est d'enlever des erreurs grossières du scanner, comme des points isolés.
- Recalage des nuages de points pour les mettre dans un repère commun. Beaucoup méthodes et algorithmes ont été développés pour automatiser un recalage sous différentes conditions, ce qui est le sujet de ce mémoire. Dans certains cas des markers sont placés sur la scène avant l'acquisition des scans et photos. Les nuages de points peuvent ensuite être fusionnés par simple concaténation des points.
- Maillage des nuages de points, par exemple par triangulation de Delaunay. Le but ici est d'obtenir un modèle qui reprend l'information sur les surfaces du modèle. Pour des formes complexes, par exemple de la végétation sur un mur, des procédures additionnelles d'analyse et de filtrage sont requis.
- Par des méthodes photogrammétriques [21] et radiométriques [7], les photos sont modifiées et analysées : On corrige des vignettes, distortions et autres erreurs optiques induits par la lentille de la caméra, égalise les valeurs colorimétriques des différentes photos. Par des détecteurs de zones d'intérêt en reconnaissance d'image, on retrouve des markers, ou d'autres points marquants, afin de mettre en correspondance plusieurs photos et d'en extraire la pose de la caméra et des informations de profondeur.
- Recalage des photos sur le modèle pour texturer le maillage. Au cas un modèle non-maillé qui reste sous forme de nuage de points, les photos peuvent être utilisés pour coloriser les points. Ensuite la densité des points peut être uniformisée si nécessaire.
- Dans certains contextes, par exemple en rétroingénierie ou en architecture, le but est de finir avec un modèle CAD. Des méthodes ont été développées pour segmenter le modèle, et pour reconnaître des formes ou objets.

2.1.1 Scanner tridimensionnels

Les scanners tridimensionnels utilisent des rayonnements, typiquement des lasers, pour physiquement mesurer des informations de profondeur de leur environnements. Dans les dernières années, cette technologie a connu un développement important. Les scanners 3D disposent d'un niveau avancé d'automatisation, et peuvent produire des données de bonne qualité [19] à des coût relativement abordables.

2.1.1.1 Scanners à temps de vol (LIDAR)

2.1.1.2 Scanners par triangulation

2.1.1.3 Scanners par décalage de phase

2.1.1.4 Scanners par lumière structurée

2.2 Théorie préliminaire

2.2.1 RANSAC

L'algorithme RANSAC ("Random Sample Consensus" *Consensus par échantillons aléatoires*), initialement décrit en [14], est une méthode générale qui permet d'aligner un *modèle*, défini par un vecteur de paramètres θ , à des échantillons p_i de données mesurés. L'algorithme procède en sélectionnant aléatoirement des échantillons pour y déduire un modèle possible, qui est ensuite raffiné itérativement. La présence d'une fraction élevée d'erreurs de mesure parmi les échantillons ("outliers"¹) rend inutilisable des solutions classiques comme la méthode des moindres carrés. Avec l'approche RANSAC, la probabilité inférieure de sélectionner parmi tous les échantillons un outlier mène à un bon alignement avec les échantillons corrects. ("inliers") Contrairement à des méthodes non-probabilistiques, RANSAC essaye de trouver une estimation initiale du modèle par un nombre minimal d'échantillons, et non pas par un nombre le plus grand possible.

Soit m le nombre minimal d'échantillons requis pour trouver un modèle $\hat{\theta}$ qui comprend ces m échantillons. Soit P l'ensemble d'échantillons. Soit $E(\theta, p)$ une métrique d'erreur qui est zéro si l'échantillon p correspond parfaitement au modèle $\hat{\theta}$. RANSAC procède en répétant la procédure suivante :

1. Soit $S \subset P$ un sous-ensemble composé de m échantillons choisis aléatoirement.
2. Calculer à partir S un modèle estimatif $\hat{\theta}$. Soit $S^* \subset P$ tous les points p de P qui correspondent au modèle : $S^* = \{p \in P : E(\hat{\theta}, p) < \epsilon\}$, pour une tolérance d'erreur ϵ donnée. S^* est appelé le *consensus set*.
3. Si $|S^*| \geq t$ pour un seuil t déterminé en fonction du nombre d'outliers, calculer l'estimation finale du modèle θ à partir de tous les échantillons du consensus set S^* , et terminer.
4. Si $|S^*| < t$, on rejette le modèle $\hat{\theta}$, et recommence à l'étape 1. Si cela arrive plus que N (nombre maximal d'itérations) fois, l'algorithme a échoué.

Une autre procédure possible serait d'au lieu d'arrêter à 3, répéter pour un nombre fixe d'itérations, et garder à la fin le modèle pour lequel $|S^*|$ était maximal.

Un exemple simple d'application serait d'aligner une droite (modèle) $y = mx + b$, définie par les paramètres $\theta = (m, b)$, à des points (échantillons) $p_i = (x_i, y_i)$. Une droite peut être trouvée à partir de $m = 2$ points, en posant $m = \frac{x_2 - x_1}{y_2 - y_1}$ et $b = y_1 - mx_1$. Pour ajuster une droite à plus que deux points (pas nécessairement alignés), la méthode des moindres carrés peut être utilisée. Une métrique d'erreur serait la distance du point à la droite, donnée par $E(\theta, p) = \frac{|y - mx - b|}{\sqrt{m^2 + 1}}$.

2.2.2 Méthode de Newton

La méthode de Newton est un algorithme qui a le but de trouver itérativement des racines d'une fonction réelle continue et dérivable. En partant d'un point x_0 proche à la racine, on construit la série $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$. Le point x_{k+1} est la solution de l'équation $f(x_k) + f'(x_k)(x - x_k) = 0$, donc le point

1. dans le contexte de nuages de points, des points qui ne sont pas sur une surface de l'objet

d'intersection de la tangente de f en x_k avec l'abscisse. Le principe d'algorithme est que les tangentes donnent une approximation du comportement de la fonction. Donc quand la racine a été trouvée, x_k sera un point stationnaire ($x_k = x_{k+1}$).

La méthode peut aussi être appliquée pour résoudre des problèmes d'optimisation, c'est à dire de minimisation d'une fonction, on considérant les racines de sa fonction dérivée f' . La formule devient

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)} \quad (2.1)$$

Ceci peut aussi être étendu pour la résolution de problèmes d'optimisation sur une variable multidimensionnelle \vec{x} . On remplace f' par le gradient $\nabla f(\vec{x})$, et $(f'')^{-1}$ par l'inverse de la matrice Hessienne 3 $(\mathbf{H}f(\vec{x}))^{-1}$:

$$\vec{x}_{k+1} = \vec{x}_k - (\mathbf{H}f(\vec{x}_k))^{-1} \nabla f(\vec{x}_k) \quad (2.2)$$

Pour éviter de passer par le calcul de la matrice inverse, le vecteur $\hat{\Delta}x_k = (\mathbf{H}f(\vec{x}_k))^{-1} \nabla f(\vec{x}_k)$, la quantité à retrancher du résultat après chaque itération, peut être trouvée par résolution du système d'équations linéaires $(\mathbf{H}f(\vec{x}_k)) \hat{\Delta}x = \nabla f(\vec{x}_k)$.⁴ Ecrit sous forme non-matricielle :

$$\begin{cases} \frac{\partial^2 f}{\partial x_1 \partial x_1} \hat{\Delta}x_1 + \frac{\partial^2 f}{\partial x_1 \partial x_2} \hat{\Delta}x_2 + \dots + \frac{\partial^2 f}{\partial x_1 \partial x_n} \hat{\Delta}x_n = \frac{df}{dx_1} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} \hat{\Delta}x_1 + \frac{\partial^2 f}{\partial x_2 \partial x_2} \hat{\Delta}x_2 + \dots + \frac{\partial^2 f}{\partial x_2 \partial x_n} \hat{\Delta}x_n = \frac{df}{dx_2} \\ \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} \hat{\Delta}x_1 + \frac{\partial^2 f}{\partial x_n \partial x_2} \hat{\Delta}x_2 + \dots + \frac{\partial^2 f}{\partial x_n \partial x_n} \hat{\Delta}x_n = \frac{df}{dx_n} \end{cases} \quad (2.3)$$

Dans la cas unidimensionnel, on prend la tangente de f' afin d'arriver au point minimal de f , qui correspond à la racine de f' . Pour trouver celle-ci on a besoin de prendre la dérivée seconde f'' . Or pour des fonctions multidimensionnelles $\mathbb{R}^n \rightarrow \mathbb{R}$, il y aura n fonctions dérivées partielles, toujours du type $\mathbb{R}^n \rightarrow \mathbb{R}$. Par conséquent il y aura n^2 fonctions dérivées secondes partielles. Ceci explique la nécessité de résoudre un système d'équations $n \times n$.

2.3 Recalage

Afin de créer un modèle complet, on doit fusionner plusieurs scans qui sont prises de différents points de vues et qui sont tous limités par le champ de vision du scanner. Ces différents nuages de points ont tous des repères différents, relatifs à la position et à l'orientation du scanner, et possiblement ayant des échelles différents.

Puisqu'il s'agit toujours de repères cartésiens orthonormaux, on peut mettre un nuage de points dans un autre repère en appliquant une matrice de transformation rigide à tous les points du nuage. Une telle transformation consiste en une translation, rotation, et dans certains cas un facteur de redimensionnement⁵. Dès que les nuages de points sont tous dans le même repère, on peut les fusionner par simple concaténation des points. En pratique, des post- et pré-traitements devront être effectués pour ajuster

2. La gradient d'une fonction vectorielle dérivable $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est le vecteur des ses n dérivées partielles :

$$\nabla f(\vec{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)^T$$

3. La matrice Hessienne d'une fonction vectorielle $f : \mathbb{R}^n \rightarrow \mathbb{R}$ dérivable deux fois est composée de toutes les combinaisons de ses dérivées partielles secondes :

$$\mathbf{H}_{i,j} f(\vec{x}) = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

4. $\hat{\Delta}x_k$ est une approximation d'un vecteur Δx_k qui résoudrait le problème en une étape.

5. Pour de pouvoir exprimer une transformation rigide (translation, rotation, redimensionnement) d'un point tridimensionnel \vec{p} en utilisant uniquement une multiplication matricielle $\vec{x}' = \mathbf{M} \vec{x}$, des *coordonnées homogènes* peuvent être utilisés pour la matrice de transformation et les points.

les densités et la distribution des points, corriger des erreurs dans les données bruts comme des points *outliers*, et autres.

Par recalage, on entend le procédé de trouver ces transformations rigides, de manière automatisé ou semi-automatisé. D'une part on a les algorithmes de recalage approximatif, donc le but est d'analyser le contenu des nuages de points et d'en identifier des régions qui représentent la même partie du modèle afin de trouver un recalage approximatif. Ensuite, ce recalage initial peut être raffiné par un algorithme de recalage précis pour bien aligner les surfaces des nuages de points. Généralement ICP est utilisé pour cela. Sachant que les nuages de points sont déjà alignés de manière à ce que les points qui représentent les mêmes parties du modèle sont proches l'un de l'autre, ICP procède en minimisant les distances entre ces points.

On peut distinguer entre les algorithmes locaux (séquentiels) qui opèrent sur deux nuages de points à la fois, et les algorithmes globaux (simultanés) qui effectuent un recalage de plusieurs nuages de points. Cette dernière méthode est plus complexe, mais a l'avantage qu'il n'y a pas d'erreur de recalage qui s'accumule lors des recalages deux-à-deux. Ces algorithmes tentent au lieu de distribuer l'erreur uniformément parmi les nuages.

La méthode préférée pour déterminer un recalage approximatif dépend surtout du type et de la forme de l'objet numérisé, et des données brutes dont on dispose. Certains algorithmes procèdent en identifiant des droites [11] ou des plans [3] dans le modèle, et sont donc plus appropriés pour par exemple des façades simples de bâtiments. Si les scans ont des zones de chevauchement assez grandes, il peut être possible d'en déduire le recalage de façon complètement automatisée. D'autres méthodes peuvent être utilisées avec des données collectionnées additionnelles, comme des photos prises par le même point de vue que le scanner [21] ou des markers placés sur l'objet avant la numérisation [22]. Par des algorithmes de détection de zones d'intérêt [16] sur des images ou directement sur les nuages de points, on peut alors identifier des points communs dans les différents scans. Aussi les informations attribuées aux points, comme une couleur, une mesure de température, ou autres, peuvent servir en tant que dimension en plus des coordonnées 3D pour déterminer leur distance. Une première estimation de la pose des scans peut être issue de sensors odométriques ou GPS du scanner.

Dans les pages suivantes certains algorithmes et méthodes seront décrits en détail, avec leurs bases mathématiques. Ils pourront possiblement être utilisés ou développés pour le projet de mémoire.

2.3.1 Iterative Closest Point

L'algorithme ICP⁶ est considéré comme la méthode standard pour l'alignement précis de deux nuages de points, après qu'un recalage approximatif initial a déjà été fait. Parmi les deux nuages de points pris comme entrée, l'un (*référence*) reste fixé, tandis que l'autre (*source*) est transformé par translation et rotation. L'algorithme procède en itérativement raffinant la transformation à chaque étape, de manière à ce que la distance entre les deux nuages de points soit minimisée.

Plus précisément, pour tout point s_i de l'ensemble *source*, on choisit un point c_i de l'ensemble *cible* pour lequel on estime qu'il représente plus au moins la même position dans le nuage de points. Comme les deux nuages de points sont déjà recalés approximativement, une méthode courante est de choisir le point le plus proche, avec la transformation actuelle. L'algorithme nécessite donc que les densités de points des deux ensembles soient similaires. Ensuite une transformation est appliquée aux points s_i qui minimise une métrique donnée de l'erreur de recalage.

La *cible* ne doit pas forcément être donnée sous forme de nuage de points, mais peut par exemple être une surface mathématique continue donnée sous forme paramétrique $(x(\vec{t}), y(\vec{t}), z(\vec{t}))$ ou implicite $g(x, y, z) = 0$. On peut alors calculer numériquement les coordonnées d'un point c_i correspondant à chaque point s_i . [15]

Quand les vecteurs normaux sur la cible sont connus, il est possible d'utiliser une variante *point-to-plane*⁷ : Au lieu de minimiser une métrique des distances entre deux points, les écarts entre les points source et les plans tangents aux points cible sont minimisés. Cette méthode a généralement une vitesse de convergence supérieure et peut mener à de meilleurs résultats. Les algorithmes utilisés à chaque itération pour calculer la minimisation ont cependant un coût numérique plus élevé. L'ICP *point-to-plane* est une alternative intéressante puisque les surfaces des objets scannés sont souvent localement planaires. [13]

6. itératif point le plus proche

7. au lieu de *point-to-point*

Plusieurs variantes de l'algorithme ont été développées qui se distinguent par le choix des couples de points, des poids associés aux couples, le rejet de certains couples, et la façon comment la métrique d'erreur est définie et minimisée. [10]

Pour la minimisation, on doit calculer une transformation rigide (généralement translation et rotation, donc 6 degrés de liberté) transforme les points s_i . Il existe plusieurs méthodes déterministes qui nécessitent pas de prendre plusieurs échantillons dans l'espace des transformations rigides. Pour le calcul de la rotation on peut par exemple utiliser la décomposition en valeurs singulières, par une représentation sous forme de matrice orthonormale ou sous forme de quaternion [8].

En général, un algorithme ICP procède selon les étapes suivantes :

1. Sélectionner des sous-ensemble de points s_i et c_i à utiliser (possiblement tous les points).
2. Former les couples (s_i, c_i) .
3. Associer des poids aux couples. (optionnel)
4. Rejeter certains couples. (optionnel)
5. Calculer une métrique d'erreur à partir des couples. Par exemple $\sum_i \|s_i - c_i\|^2$.
6. Appliquer une transformation rigide aux points s_i qui minimise l'erreur.
7. Si l'erreur est inférieur à une valeur de seuil donnée, arrêter. Sinon, continuer avec 1 ou 2.

2.3.1.1 Calcul de la transformation par quaternions

Une manière de calculer la translation et rotation qui est appliquée à chaque itération à l'ensemble de points *source* est décrite dans [15] et [8]. La procédure prend uniquement les n couples de points (\vec{s}_i, \vec{c}_i) comme entrée, où \vec{c}_i est un point de l'ensemble *cible* C , et \vec{s}_i un point de l'ensemble *source* S . On suppose que les transformations données par les itérations précédentes ont déjà été appliquées aux points s_i . La méthode reste valable pour tout choix de points, et C ne doit pas forcément être donné sous forme d'ensemble de points, mais ses points \vec{c}_i peuvent aussi par exemple être calculés à partir d'une surface paramétrique.

Le but de trouver \vec{q}_T et \vec{q}_R qui minimisent le carré des distances des couples $f(\vec{q})$.

$$f(\vec{q}) = \frac{1}{n} \sum_{i=1}^n \|\vec{c}_i - \mathbf{R}\vec{s}_i - \vec{q}_T\|^2 \quad (2.4)$$

$\vec{q}_T = (q_4 q_5 q_6)^T$ donne la translation, et \mathbf{R} la matrice de rotation 3x3.

On cherche une transformation de la forme $\vec{t}' = \mathbf{R}(\vec{s}) + \vec{q}_T$, donc une rotation, suivie par une translation à appliquer aux points s_i , qui minimise les distances des points transformés t_i aux points c_i correspondants dans le nuage de points *cible*. Car on ne peut pas assumer que les deux nuages S et C auront exactement la même distribution de points, les erreurs $e_i = \vec{c}_i - \vec{t}_i$ ne peuvent en général pas devenir 0. On minimise la somme des carrés des erreurs $\sum \|e_i\|^2$. Le développement décrit en [8] inclut aussi un facteur de redimensionnement, mais pour ICP on suppose généralement que les deux nuages de points ont déjà la même échelle. Un redimensionnement durant les itérations introduirait des problèmes avec le choix des couples de points.

Pour le développement suivant, on prend les coordonnées des points \vec{s}_i et \vec{c}_i , relativement au centres de masse des ensembles. On définit

$$\vec{\mu}_s = \frac{1}{n} \sum_i \vec{s}_i \quad \text{et} \quad \vec{\mu}_c = \frac{1}{n} \sum_i \vec{c}_i \quad (2.5)$$

Et pour tout i , on pose $\vec{s}'_i = \vec{s}_i - \vec{\mu}_s$ et $\vec{c}'_i = \vec{c}_i - \vec{\mu}_c$. Donc $\sum \vec{s}'_i = 0$ et $\sum \vec{c}'_i = 0$. L'erreur e_i peut être réécrit comme $e_i = \vec{c}'_i - \vec{t}'_i = \vec{c}'_i - \mathbf{R}(\vec{s}'_i) - \vec{q}'_T$. On peut montrer que la somme des carrés des erreur sera minimale quand $\vec{q}'_T = 0$, et donc la translation à appliquer correspondra à $\vec{q}_T = \vec{q}_T - \mathbf{R}(\vec{\mu}_s)$:

En fait, on a que $\vec{q}'_T = \vec{q}_T - \vec{\mu}_c + \mathbf{R}(\vec{\mu}_s)$. La somme des carrés peut être développée en

$$\sum_{i=1}^n \|\vec{c}'_i - \mathbf{R}(\vec{s}'_i)\|^2 - 2\vec{q}'_T \sum_{i=1}^n (\vec{c}'_i - \mathbf{R}(\vec{s}'_i)) + n\|\vec{q}'_T\|^2 \quad (2.6)$$

Le second terme sera toujours 0 puisque les coordonnées sont pris relatif aux centres de masse. Le premier ne dépend pas de \vec{q}'_T . Donc l'expression est minimisée par $\vec{q}'_T = 0 \iff \vec{q}_T = \vec{\mu}_c - \mathbf{R}(\vec{\mu}_s)$.

Pour trouver la rotation \mathbf{R} , on maximise

$$\sum_{i=1}^n \vec{c}'_i \cdot \mathbf{R}(\vec{s}'_i) \quad (2.7)$$

En effet, le produit scalaire de deux vecteurs est maximal quand ils ont la même direction. On cherche la rotation sous forme d'un quaternion \dot{q}_R .⁸

Une rotation peut être encodée dans un quaternion unitaire, c'est à dire pour lequel $q_0 \geq 0$ et $q_0^2 + q_1^2 + q_2^2 + q_3^2 = 1$. \dot{q} est purement imaginaire si $q_0 = 0$. (Les trois autres composants peuvent être considérés comme termes imaginaires comme chez les nombres complexes.) On représente un vecteur sous forme de quaternion purement imaginaire, en mettant ses coordonnées dans q_1, q_2, q_3 . On peut montrer que si \dot{s} est purement imaginaire et \dot{q}_R est unitaire, alors $\dot{q}_R \dot{s} \dot{q}_R^*$ reste purement imaginaire, et peut donc représenter une opération sur un vecteur. \dot{q}_R^* est le conjugué de \dot{q}_R .

L'article [8] montre qu'en utilisant les propriétés des quaternions, on peut former à partir des ensembles de points \vec{s}_i et \vec{c}_i une matrice symétrique 4x4 \mathbf{N} telle que

$$\sum_{i=1}^n \vec{c}'_i \cdot \mathbf{R}(\vec{s}'_i) = \sum_{i=1}^n \dot{c}'_i \cdot (\dot{q}_R \dot{s}'_i \dot{q}_R^*) = \dot{q}_R \mathbf{N} \dot{q}_R^* \quad (2.9)$$

Il est aussi montré que le quaternion unitaire \dot{q}_R qui maximise l'expression est le vecteur propre correspondant à la valeur propre la plus grande de \mathbf{N} . Le calcul des valeurs propres nécessite la résolution d'une équation polynomiale du quatrième degré. Il existe des solutions de forme fermée pour ce problème.

Donc, cette méthode permet de déterminer la rotation et translation à appliquer à \mathbf{M} par une série de calculs, sans passer par des méthodes approximatives.

2.3.1.2 Variantes de l'algorithme

Comme mentionné, diverses variantes de l'ICP sont possibles. [10] donne un comparatif des différentes possibilités.

2.3.1.3 Analyse procustéenne généralisée

Le problème de trouver une transformation rigide qui minimise une distance d'un ensemble de couples de points donnés $(x_{1,i}, x_{2,i})$ peut aussi être résolu par *analyse procustéenne*. L'*analyse procustéenne généralisée* ("GPA") permet d'avoir au lieu de couples des k -uplets $(x_{1,i}, x_{2,i}, \dots, x_{k,i})$, choisis parmi k ensembles de points. En général, l'analyse procustéenne sert à aligner des *formes*, ce qui peut être vu comme l'information géométrique qui reste d'un objet après avoir éliminé sa position, orientation et échelle. La méthode est utilisé dans beaucoup de domaines, notamment en statistique.

Soit n le nombre de couples. On encode la liste des k -uplets via k matrices modèle $n \times 3$ \mathbf{X}_j , dont les colonnes contiennent les 3 coordonnées des j -ième éléments des tuples. Ces matrices contiennent donc tous approximativement les mêmes points, hormis une transformation rigide.

On définit la *cible* \mathbf{K} comme

$$\mathbf{K} = \frac{1}{k} \sum_{j=1}^k \mathbf{X}'_j \quad (2.10)$$

La matrice \mathbf{X}'_j , encore inconnu, correspond à la version transformée \mathbf{X}_j .

Le principe de analyse procustéenne généralisée est le suivant : D'abord \mathbf{K} est initialisé à une valeur donnée. Pour toute matrice modèle \mathbf{X}_j , on calcule via une solution directe \mathbf{X}'_j qui est aligné le mieux

8. Une matrice de rotation \mathbf{R} peut en être déduit à partir d'un quaternion $\dot{q} = (q_0 q_1 q_2 q_3)^T$ par la formule

$$\mathbf{R} = \begin{bmatrix} q_0^2 + q_1^2 - q_2^2 - q_3^2 & 2(q_1 q_2 - q_0 q_3) & 2(q_1 q_3 + q_0 q_2) \\ 2(q_1 q_2 + q_0 q_3) & q_0^2 + q_2^2 - q_1^2 - q_3^2 & 2(q_2 q_3 - q_0 q_1) \\ 2(q_1 q_3 - q_0 q_2) & 2(q_2 q_3 + q_0 q_1) & q_0^2 + q_3^2 - q_1^2 - q_2^2 \end{bmatrix} \quad (2.8)$$

avec le centroid. Par après, on recalcule \mathbf{K} par la formule 2.10. Le processus est itéré jusqu'à ce que \mathbf{K} se stabilise. [6]

Donc on doit trouver, pour tous les k matrices \mathbf{X}_j , une matrice orthogonale de rotation \mathbf{R}_j , un vecteur de translation \vec{t} et un facteur de homothétie c qui minimise

$$\|\mathbf{X}'_j\| = \|c\mathbf{X}_j\mathbf{R}_j + j\vec{t}^T - \mathbf{K}\| \quad (2.11)$$

où j est un vecteur unitaire 3×1 , et $\|\mathbf{X}\|$ représente la norme de Frobenius.⁹

Une solution de l'analyse procustéenne qui permet de trouver \mathbf{X}'_j et la procédure qui permet de calculer ce résultat sont données dans [17] et [18].

2.3.1.4 Version simultanée de l'ICP

Une approche qui permet de faire un recalage ICP *simultané* de plusieurs nuages de points en utilisant l'analyse procustéenne généralisée est décrite dans [6].

Comme montré dans la section précédente, une solution du problème GPA est l'aligner les nuages de points à une *cible* \mathbf{K} générée artificiellement à partir de tous les nuages de points, au lieu de les aligner à un autre nuage de points donné comme entrée. Ceci est appliqué pour rendre l'ICP *simultané*, de manière à ce qu'il n'y a pas d'erreur qui s'accumule.

Pour le choix des tuples $(x_{1,i}, x_{2,i}, \dots, x_{k,i})$, l'article propose de choisir des tuples dans lesquelles tous les paires de points sont *mutuellement voisins les plus proches*. Deux points $\vec{a} \in A$ et $\vec{b} \in B$ sont considérés mutuellement voisins les plus proches si \vec{a} est le point le plus proche à \vec{b} dans A , et \vec{b} est le point le plus proche de \vec{a} dans B . On forme un graphe ayant comme sommets les points de tous les nuages, et les couples de sommets qui remplissent cette conditions sont connectés par des arrêtes. Les tuples à choisir correspondent aux sous-ensembles indépendants dans ce graphe. La solution de GPA est donnée qui fonctionne aussi si les tuples ne sont pas toujours complets (donc pour certains nuages de points il n'ont pas de point correspondant), et inclut la possibilité d'associer des poids aux tuples. Cela est nécessaire parce que pour en grand nombre de nuages de points à recalcr, il n'y aura dans la plupart des cas seulement relativement peu de tuples complets.

La version initiale de la cible \mathbf{K} est formée par les centroids des tuples. L'algorithme GPA-ICP peut alors être formulé comme suit : [6]

Entrée : n nuages de points p_i

Sortie : n matrices de transformation \mathbf{M}_i

1. Initialiser \mathbf{M}_i par matrices d'identité
2. Trouver les tuples de points correspondants
3. Former la cible \mathbf{K} à partir des centroids des tuples
4. Estimer par GPA les transformations rigides qui alignent $\{p_i\}$ à la cible
5. Appliquer ces transformations aux points $\{p_i\}$, et ajouter les aux matrices \mathbf{M}_i
6. Répéter depuis 2, jusqu'à ce que \mathbf{K} est stabilisé (ou un nombre limite d'itérations a été dépassé)

Après l'exécution de cet algorithme, les n nuages de points sont recalés dans un repère commun qui n'est pas spécifié d'avance. Donc un recalage complémentaire est nécessaire pour mettre le nuage fusionné dans le repère désiré.

2.3.1.5 ICP généralisé

Pour ce mémoire, il sera nécessaire de trouver des méthodes qui permettent de recalcr des nuages de points à densités de points différents. Une version *généralisée* du ICP est développée dans [20] : On prend en compte que les nuages de points ne sont qu'une approximation des surfaces scannées, et on représente l'aspect de ces surfaces sous-jacentes via un modèle probabilistique.

9. La norme de Frobenius d'une matrice $m \times n$ \mathbf{X} est défini comme racine carrée de la somme des carrés de tous les éléments de \mathbf{X} . On a :

$$\|\mathbf{X}\| = \sqrt{\sum_{i=1}^m \sum_{j=1}^n \|x_{i,j}\|^2} = \text{tr}(\mathbf{X}^* \mathbf{X}) \quad (2.12)$$

Pour cet algorithme, l'étape de minimisation est altérée. Les autres étapes (choix des couples de points, etc.) peuvent toujours être implémentés via les différentes variantes proposées. On suppose qu'il existe des nuages de points $\hat{S} = \{\hat{s}_i\}$ et $\hat{C} = \{\hat{c}_i\}$ sous-jacents aux nuages de points source S et cible C donnés, qui sont tels qu'il existe une matrice de transformation rigide \mathbf{M}^* qui recale parfaitement \hat{S} et \hat{C} . Donc $\hat{c}_i = \mathbf{M}^* \hat{s}_i$ pour tout i .

\hat{S} et \hat{C} constituent une version idéalisée de la représentation de la surface par nuage de points. Avec S et C , un recalage parfait n'est généralement pas faisable.

On suppose aussi que les points de S et C sont des variables aléatoires tirés de \hat{S} et \hat{C} par une loi normale multidimensionnelle

$$s_i \sim \mathcal{N}(\hat{s}_i, \mathbf{C}_i^S) \quad \text{et} \quad c_i \sim \mathcal{N}(\hat{c}_i, \mathbf{C}_i^C) \quad (2.13)$$

où \mathbf{C}_i^S et \mathbf{C}_i^C sont des matrice de variance-covariance qu'on associe à chaque point de S et C . Ces matrices vont être paramétrisés pour décrire la surface autour de \hat{s}_i respectivement \hat{c}_i . Ils représentent la distribution de probabilité des positions de s_i et c_i .

La distance entre deux points pour une matrice de transformation \mathbf{M} est donnée par $d_i^{(\mathbf{M})} = c_i - \mathbf{M} s_i$. Le but sera de trouver \mathbf{M} qui minimise $\sum_i \|d_i^{(\mathbf{M})}\|^2$. Dans ce modèle, les $d_i^{(\mathbf{M})}$ sont eux-mêmes des variables aléatoires. Vu que a_i et b_i sont tirés d'une loi normale multidimensionnelle, la distribution de $d_i^{(\mathbf{M})}$ est

$$d_i^{(\mathbf{M})} \sim \mathcal{N}(\hat{c}_i - \mathbf{M} \hat{s}_i, \mathbf{C}_i^C + \mathbf{M} \mathbf{C}_i^S \mathbf{M}^T) \quad (2.14)$$

Par conséquent,

$$d_i^{(\mathbf{M}^*)} \sim \mathcal{N}(0, \mathbf{C}_i^C + (\mathbf{M}^*) \mathbf{C}_i^S (\mathbf{M}^*)^T) \quad (2.15)$$

La méthode d'estimation du maximum de vraisemblance est utilisée dont le principe est le suivant : On a n échantillons x_1, \dots, x_n issus d'une variable aléatoire X , et on cherche la fonction de densité $f^{(\theta^*)}$ de probabilité associée à X , en sachant qu'elle appartient à une famille de fonctions de densité de probabilité, paramétrisée par θ . Quand X est discrète, la fonction de masse $p^{(\theta^*)}$ est utilisée. Donc on calcule une estimation de θ^* à partir de x_1, \dots, x_n et f . Pour une valeur du paramètre θ donnée, et on supposant que les échantillons sont mutuellement indépendants, la *fonction de vraisemblance* peut être calculée par

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f^{(\theta)}(x_i) \quad (2.16)$$

Une estimation de θ^* peut alors être trouvée en maximisant L :

$$\hat{\theta} = \arg \max_{\theta} L(\theta; x_1, \dots, x_n) \quad (2.17)$$

On considère que $d_i^{(\mathbf{M})}$ sont des échantillons. En fixant \mathbf{C}_i^S et \mathbf{C}_i^C , a fonction de masse des échantillons $p^{\mathbf{M}}$ peut être calculée avec \mathbf{M} comme seule inconnue. Par une application récursive de l'estimation du maximum de vraisemblance, une valeur pour \mathbf{M} pourra être trouvée :

$$\mathbf{M} = \arg \max_{\mathbf{M}} \prod_{i=1}^n p^{\mathbf{M}}(d_i^{(\mathbf{M})}) = \arg \max_{\mathbf{M}} \sum_{i=1}^n \log(p^{\mathbf{M}}(d_i^{(\mathbf{M})})) \quad (2.18)$$

La somme des logarithmes peut être maximisée au lieu parce que la fonction log est strictement croissante.

En utilisant 2.14, la formule peut être simplifiée en

$$\mathbf{M} = \arg \min_{\mathbf{M}} \sum_{i=1}^n (d_i^{(\mathbf{M})})^T (\mathbf{C}_i^C + \mathbf{M} \mathbf{C}_i^S \mathbf{M}^T)^{-1} d_i^{(\mathbf{M})} \quad (2.19)$$

C'est cela qui constitue l'amélioration du ICP généralisé par rapport au ICP standard : Au lieu de minimiser la métrique d'erreur $\sum_i \|d_i^{(\mathbf{M})}\|$, on minimise $\sum_i (d_i^{(\mathbf{M})})^T (\mathbf{C}_i^C + \mathbf{M} \mathbf{C}_i^S \mathbf{M}^T)^{-1} d_i^{(\mathbf{M})}$. On le recalcule plus directement les points S et P , mais les surfaces sous-jacentes. Les surfaces à recaler sont les

mêmes (vu de différentes perspectives), mais les points S et P ne représentent en général pas exactement les mêmes positions sur la surface, contrairement aux “vrais” points \hat{S} et \hat{P} . Par cette méthode, on ne suppose plus cela, mais plutôt on introduit une incertitude sur la position des points donnés par rapport aux vrais points, qui est décrite par les matrices de variance-covariance \mathbf{C}_i^S et \mathbf{C}_i^C . Donc l’algorithme correspond à une approche *plane-to-plane*, augmentée par une distribution de probabilité sur les plane, de l’ICP.

Pour un point avec le premier vecteur directeur du repère orthonormal comme vecteur normal, la matrice

$$\begin{bmatrix} \epsilon & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.20)$$

avec ϵ un petit nombre, indique une grande certitude sur la position du point le long de la direction du vecteur normal, mais une petite certitude sur la position du point dans le plan tangent. Comme la surface est souvent localement planaire, ce plan est une approximation de la surface. Soit \mathbf{R}_{s_i} et \mathbf{R}_{c_i} les matrices de changement de base de ce dernier repère, vers un repère dont le premier vecteur directeur est le vecteur normal du point s_i respectivement c_i , sans translation. \mathbf{C}_i^S et \mathbf{C}_i^C peuvent maintenant être calculées par

$$\mathbf{C}_i^S = \mathbf{R}_{s_i} \begin{bmatrix} \epsilon & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \mathbf{R}_{s_i}^T \quad \text{et} \quad \mathbf{C}_i^C = \mathbf{R}_{c_i} \begin{bmatrix} \epsilon & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \mathbf{R}_{c_i}^T \quad (2.21)$$

Il a été expérimentalement montré que la méthode génère des résultats supérieurs au ICP standard. [20] Cependant, puisqu’elle suppose que les surfaces sont localement planaires, et que \mathbf{C}_i^S et \mathbf{C}_i^C donnent une bonne estimation de la forme de la surface.

L’article [1] présente une manière de calculer les vecteurs normaux (et donc les matrices via 2.21), dans le contexte de nuages de points à densités non-uniformes pris par un scanner 3D composé d’un télémètre laser 2D tournant. Le télémètre capture seulement des *scan lines* 2D, c’est à dire des valeurs de profondeur de points dans un plan (vertical) sortant du scanner, et non pas dans un champ de vision tridimensionnel. Durant les rotations, plusieurs scan lines sont pris dans différentes. La distance de points voisins en direction horizontale (donc provenant de deux scan lines) sera plus grande à celle en direction verticale, sur une même scan line.

Il ne suffit donc plus de comparer les points voisins pour avoir une estimation du vecteur normal. La méthode proposée procède en créant un maillage à quadrilatères, formée par points voisins sur une scan line, connectés les deux points correspondants de la scan line voisine. Ces derniers points ne seraient pas inclus par une recherche de points voisins classique. Après filtrage du maillage, les normaux sont maintenant estimés en considérant les points adjacents sur le maillage, pour un rayon de recherche donné.

2.4 4-Points Congruent Sets

La méthode 4-Points Congruent Sets¹⁰ (4PCS) est une approche qui permet de recalculer deux nuages de points avec du bruit (i.e. outliers), relativement peu d’information commune, et sans avoir besoin d’un recalage initial. Elle est basée sur une variante du RANSAC appliqué sur des échantillons bien choisis.

Le principe de RANSAC est de trouver par recherche aléatoire un nombre minimal d’échantillons à partir desquelles une approximation assez bonne d’un modèle peut être trouvée, et puis de raffiner cette approximation en utilisant uniquement les échantillons (inliers) assez proches. Pour le problème du recalage de deux nuages de points S et C , le modèle à chercher est une matrice de transformation \mathbf{M} qui recalcule assez bien les deux nuages. Une telle matrice peut être univoquement définie par deux triplets de points sans les repères de S et C respectivement. Une méthode pour en déduire \mathbf{M} est donnée en [8]. \mathbf{M} représente le recalage correct si les points des deux triplets représentent toujours les mêmes positions dans les deux nuages de points.

Une manière d’appliquer RANSAC est donc de choisir comme échantillons aléatoirement ces deux triplets de points, et de calculer et vérifier les matrices de transformation correspondantes. Le consensus set est l’ensemble de points de $s \in S$ pour lesquels $\min_{c \in C} \|s - c\| < \epsilon$. On peut raffiner le recalage par

10. ensemble congruents de 4-points

exemple avec ICP. La plupart de ces échantillons ne formeront pas un recalage correct. Une telle méthode aurait une complexité d'au moins $O(n^3 \log n)$. Pour la rendre utilisable, il faut donc altérer la façon de choisir des échantillons.

La méthode 4PCS utilise comme échantillon deux 4-points (i.e. quadruples de points) prises de S et de C . Ceci permettra d'arriver à une complexité quadratique au lieu de cubique. A partir de S , on choisit aléatoirement quatre points qui sont coplanaires. Ces quatre points sont appelés la *base*. En pratique, une coplanarité approximative est suffisante. Pour le deuxième quadruple, on choisit ceux qui sont congruents avec le premier, c'est à dire que le premier peut être transformé en le deuxième par une transformation rigide. L'algorithme fonctionne selon la procédure suivante :

1. Sélectionner aléatoirement base \dot{b} (quadruple de points coplanaires) de S .
2. Trouver l'ensemble U des quadruples congruents à la base.
3. Pour tout $\dot{u}_i \in U$, calculer la matrice de transformation \mathbf{M}_i qui aligne \dot{u}_i à \dot{b} . La solution à forme fermée développée en 2.3.1.1 peut être utilisée pour aligner deux ensembles de 4 points. Le consensus set $S_i \cup S$ est formé par les points de la source qui sont après la transformation \mathbf{M}_i assez bien recalés à la cible :

$$S_i = \{s \in S : \min_{c \in C} \|c - \mathbf{M}_i s\| < \delta\} \quad (2.22)$$

4. On retient le consensus set S_k et la matrice de transformation \mathbf{M}_k correspondante pour lequel $|S_i|$ était maximal. \mathbf{M}_k correspond à la meilleure transformation qui a pu être trouvée avec la base \dot{b} .
5. Un compteur est incrémenté. S'il n'a pas encore dépassé un nombre fixé L , on continue avec l'étape 1. Sinon, l'algorithme se termine. A la fin on garde la matrice \mathbf{M}_k pour laquelle $|S_k|$ était maximal.

L'opération fondamentale de l'algorithme est la recherche the quadruplets $\dot{u} = (\vec{u}_1, \vec{u}_2, \vec{u}_3, \vec{u}_4)$ congruents à une base $\dot{b} = (\vec{b}_1, \vec{b}_2, \vec{b}_3, \vec{b}_4)$ donnée. Les points de la base sont coplanaires, par définition. Il y aura toujours deux paires dans la base qui forment des droites qui s'intersectent. Sans perte de généralité, soit $\vec{u}_1\vec{u}_2$ et $\vec{u}_3\vec{u}_4$ ces droites, et \vec{e} leur point d'intersection. Il a été montré que les deux nombres

$$r_1 = \frac{\|\vec{u}_1 - \vec{e}\|}{\|\vec{u}_1 - \vec{u}_2\|} \quad \text{et} \quad r_2 = \frac{\|\vec{u}_3 - \vec{e}\|}{\|\vec{u}_3 - \vec{u}_4\|} \quad (2.23)$$

sont invariants par rapport à la transformation affine de \dot{b} . De plus, in changent toujours quand une transformation non-affine est appliqué. Donc pour trouver des candidats pour \dot{u} , il suffit de chercher les quadruples qui produisent les mêmes valeurs r_1 et r_2 .

On considère tous des paires de points $(\vec{s}_1, \vec{s}_2) \in S$, on faisant l'hypothèse qu'ils appartiennent à un des quadruples \dot{u} cherchés, et qu'ils sont congruents à soit (\vec{b}_1, \vec{b}_2) ou (\vec{b}_3, \vec{b}_4) . Donc ils forment une des droites qui passent par leur équivalent de \vec{e} . Des paires sont cherchés dans les deux ordres, c'est à dire on considère (\vec{s}_1, \vec{s}_2) et (\vec{s}_2, \vec{s}_1) séparément. Puisqu'on ne sait pas quelles des deux droites ils représentent, il y a deux possibilités \vec{e}_1 et \vec{e}_2 pour la position du point d'intersection de ce quadruple :

$$\vec{e}_1 = \vec{s}_1 = r_1 (\vec{s}_2 - \vec{s}_1) \quad \text{ou} \quad \vec{e}_2 = \vec{s}_1 = r_2 (\vec{s}_2 - \vec{s}_1) \quad (2.24)$$

Si deux paires de points (\vec{s}_1', \vec{s}_2') et $(\vec{s}_1'', \vec{s}_2'')$ ont pu être trouvés tels que $\vec{e}_1' = \vec{e}_2''$, alors il est probable qu'ils forment un des quadruples congruents cherchés.

L'algorithme procède par filtrer les quadruples qui ne sont pas congruents avec la base. Dans l'implémentation donnée par [5], l'algorithme considère seulement les paires (\vec{s}_1, \vec{s}_2) dont la distance correspond approximativement à $\|\vec{b}_1 - \vec{b}_2\|$ ou $\|\vec{b}_3 - \vec{b}_4\|$. Les points \vec{e} sont mis sur une structure *range tree*, ce qui permet de trouver des partenaires coïncidents \vec{e}' de façon efficace. La procédure a une complexité dans $O(n^2 + k)$, où k est le nombre de quadruplets \dot{u} qui seront trouvés. (L'algorithme est *output-sensitive*.)

Pour choisir une base \dot{b} , l'algorithme choisit d'abord aléatoirement trois points de C . On préfère des points à distance plutôt élevée, afin que la base ne soit pas perturbé par des imprécisions locales. On cherche ensuite le quatrième point de manière à ce qu'il soit coplanaire avec les trois autres.

2.5 Normal Distributions Transform

Dans le context de la robotique, la méthode NDT¹¹ a été développée pour aligner deux nuages de points 2D qui représente les distances d'objets autour d'un robot mobile qui se déplace sur un plan horizontal. [2] Ce recalage permet de construire une carte 2D des environs du robot, qui consiste en une translation 2D et une rotation sur une axe, dénotées par les paramètres $\theta = (t_x, t_y, \phi)$. La méthode est par exemple utilisée pour mesurer la position précise du robot en partant par une estimation calculée par des données odométriques.

L'idée est d'au lieu de recaler directement des points comme ICP, on recale leur *transformée en distribution normale*, une représentation continue et dérivable du nuage de points par morceaux du nuage de points qui consiste en la distribution de probabilité qu'un point soit à une position. La NDT est calculée à partir d'un nuage de points cible $C = \{\vec{c}_i\}$ de manière suivante. On commence par subdiviser l'espace 2D en une grille régulière avec une taille donnée des cellules. Soit C_j l'ensemble des points qui se trouvent dans la cellule j . Pour tous les cellules qui contiennent au moins 3 points, on peut modéliser la probabilité $p(\vec{x})$ d'y trouver un point à la position \vec{x} :

Soit $\vec{\mu}_j = \frac{1}{n_j} \sum_i \vec{c}_{j,i}$ la moyenne des points dans la cellule. La matrice de variance-covariance qui représente la distributions des points C_j est calculée par $\mathbf{C}_j = \frac{1}{n_j-1} \sum_i (\vec{c}_{j,i} - \vec{\mu}_j)(\vec{c}_{j,i} - \vec{\mu}_j)^T$. La matrice exprime une distribution de Gauss en deux dimensions, ajusté sur la distributions des points. $p(\vec{x})$ peut être calculé par la fonction caractéristique :

$$p(\vec{x}) = \exp \left(-\frac{(\vec{x} - \vec{\mu}_j)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_j)}{2} \right) \quad (2.25)$$

Similairement au ICP, l'algorithme procède en raffinant itérativement une estimation de la transformation (t_x, t_y, ϕ) cherchée. La fonction de transformation T est exprimée par

$$T_\theta : \vec{p} \mapsto \begin{bmatrix} \cos \phi & -\sin \phi \\ \sin \phi & \cos \phi \end{bmatrix} \begin{bmatrix} p_x \\ p_y \end{bmatrix} + \begin{bmatrix} t_x \\ t_y \end{bmatrix} \quad (2.26)$$

Les étapes suivies par l'algorithme pour recaler un nuage de points source S à un nuage de points cible C sont les suivantes :

1. Créer la NDT pour C , et initialiser une estimation des paramètres de recalage $\theta = (t_x, t_y, \phi)$ (possiblement en utilisant des données odométriques enregistrées par le robot).
2. Mettre les points S dans le repère de C , en appliquant la transformation T_θ .
3. Pour tous les points transformés $\vec{s}'_i = T(\vec{s}_i)$, trouver sa cellule j et les \mathbf{C}_j , $\vec{\mu}_j$ correspondants.
4. On sait que $p(\vec{x})$ exprime la probabilité qu'un point de C se trouve à la position \vec{x} . La somme $\sum_i p(\vec{x}_i)$ est donc maximale si les \vec{x}_i représentent tous des positions de points, par exemple si $\{\vec{x}_i\} = C$, donc si le recalage est parfait. L'algorithme va donc maximiser une fonction *score* des paramètres θ donnée par

$$\text{score}(\theta) = \sum_i \exp \left(-\frac{(\vec{s}'_i - \vec{\mu}_j)^T \mathbf{C}_j^{-1} (\vec{s}'_i - \vec{\mu}_j)}{2} \right) \quad (2.27)$$

5. Calculer des nouveaux paramètres de transformation θ par maximisation de la fonction *score*.
6. Tant que le recalage n'est pas encore assez bon, répéter avec l'étape 2.

Comme montré dans la section 2.2.2, on peut utiliser la méthode de Newton multidimensionnelle pour ce problème de maximisation : On minimise la fonction opposée $-\text{score}$. Puisqu'il y a trois paramètres (t_x, t_y, ϕ) et la fonction *score* calcule un réel, on est dans le cas $\mathbb{R}^3 \rightarrow \mathbb{R}$. Pour chaque itération de l'algorithme de Newton résoud le système

$$[\mathbf{H} \text{score}(\theta)] \Delta\theta = \nabla \text{score}(\theta) \quad (2.28)$$

en utilisant la définition de la fonction *score*.

11. transformée en distribution normale

2.6 Extended Gaussian Images

On peut générer à partir d'un nuage de point son EGI (Extended Gaussian Image), qui est une forme d'encoder la forme d'un objet convexe. Ceci permet d'estimer la rotation à appliquer, sans partir d'un recalage initial.

2.7 Extended Gaussian Images

2.8 Identification et correspondance de droites

2.9 Identification et correspondance de plans

2.10 Détecteurs de zones d'intérêt

2.11 Recalage via des photos

2.12 Photogrammétrie

3 Projet prévu pour le mémoire

Bibliographie

- [1] Dirk Holz ; Sven Behnke. Registration of non-uniform density 3d point clouds using approximate surface reconstruction. Joint 45th International Symposium on Robotics (ISR) and 8th German Conference on Robotics (ROBOTIK), Munich, June 2014. Autonomous Intelligent Systems Group, University of Bonn, Germany.
- [2] Peter Biber. The normal distributions transform : A new approach to laser scan matching. 2003.
- [3] Christoph Dold ; Claus Brenner. Registration of terrestrial laser scanning data using planar patches and image data. In *International Archives of Photogrammetry and Remote Sensing*, pages 25–27. Leibniz University of Hannover, 2006.
- [4] University of Arkansas Center for Advanced Spatial Technologies. Archaeological laser scanning. <http://www.cast.uark.edu/home/research/archaeology-and-historic-preservation/archaeological-geomatics/archaeological-laser-scanning.html>, 2014.
- [5] Dror Aiger ; Niloy J. Mitra ; Daniel Cohen-Or. 4-points congruent sets for robust pairwise surface registration. *ACM Transactions on Graphics*, 27(3), 2008.
- [6] Roberto Toldo ; Alberto Beinat ; Fabio Crosilla. Global registration of multiple point clouds embedding the generalized procrustes analysis into an icp framework. 3DPVT 2010 Conference, 2010.
- [7] Luc Girod. Égalisation radiométrique de nuages de points 3d : Principes et algorithmique. Stage de fin d'études, Ecole Nationale des Sciences Géographiques (France), Septembre 2013.
- [8] Berthold K.P. Horn. Closed-form solution of absolute orientation using unit quaternions. In *Journal of the Optical Society of America A*, volume 4, page 629. Department of Electrical Engineering, University of Hawaii at Manoa, April 1987.
- [9] Christopher Keiner. Bildregistrierung von 3d-laserscans und bildern für wadi sura. Master's thesis, Fachbereich Mathematik und Informatik der Freien Universität Berlin, April, 2011.
- [10] Szymon Rusinkiewicz ; Marc Levoy. Efficient variants of the icp algorithm. volume 3-D Digital Imaging and Modeling, pages 145–152. Stanford University, 2001.
- [11] Maria Lichtenstein. *Strukturbasierte Registrierung von Punktwolken unter Verwendung von Bild- und Laserscannerdaten*. PhD thesis, Rheinisch-Westfälische Technische Hochschule Aachen, 2011.
- [12] Thomas Kersten ; Heinz-Jürgen Przybilla ; Maren Lindstaedt. Integration, fusion und kombination von terrestrischen laserscannerdaten und digitalen bildern. November 2006.
- [13] Kok-Lim Low. Linear least-squares optimization for point-to-plane icp surface registration. Technical report, Department of Computer Science ; University of North Carolina at Chapel Hill, February 2004.
- [14] Robert C Bolles Martin A Fischler. Random sample consensus : A paradigm for model fitting with applications to image analysis and automated cartography. Technical report, Artificial Intelligence Center, SRI International, Menlo Park, California, March 1980.
- [15] Paul J Besl ; Neil D. McKay. A method for registration of 3-d shapes. In *IEEE Transactions on Pattern Analysis and Machine Intelligence*, volume 14, pages 239–256. IEEE, February 1992.
- [16] Tinne Tuytelaars ; Krystian Mikolajczyk. Local invariant feature detectors : A survey. *Foundations and Trends in Computer Graphics and Vision*, 3(3), 2007.
- [17] Robert M Carroll Peter H Schönemann. Fitting one matrix to another using choice of a central dilation and a rigid motion. *Phychometrika*, 35(2) :245–255, June 1970.
- [18] Peter H Schönemann. A generalized solution of the orthogonal procrustes problem. *Phychometrika*, 31(1) :1–10, March 1966.

- [19] P. Grussenmeyer ; E. Alby ; T. Landes ; M. Koehl ; S. Guillemin ; J.-F. Hullo ; P. Assali ; E. Smigiel. Recording approach of heritage sites based on merging point clouds from high resolution photogrammetry and terrestrial laser scanning. *International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, XXXIX-B5 :553–558, 2012.
- [20] Aleksandr V. Segal ; Dirk Haehnel ; Sebastian Thrun. Generalized-icp. *Proceedings of Robotics : Science and Systems*, 2009.
- [21] E. Tournas ; M. Tsakiri. Automatic 3d point cloud registration for cultural heritage documentation. *Laser scanning 2009, IAPRS*, XXXVIII :189–194, September 2009.
- [22] D. Miniotas V. Matiukas. Point cloud merging for complete 3d surface reconstruction. Number 7 in ISSN 1392–1215 ELECTRONICS AND ELECTRICAL ENGINEERING. Department of Electronic Systems, Vilnius Gediminas Technical University, 2011.
- [23] José Luis Lerma ; Santiago Navarro ; Miriam Cabrelles ; Valentín Villaverde. Terrestrial laser scanning and close range photogrammetry for 3d archaeological documentation : the upper palaeolithic cave of parpalló as a case study. *Journal of Archaeological Science*, 37 :499–507, October 2009.